

# Word2vec笔记

Kevin

2020-06-28



# Contents

|          |                               |          |
|----------|-------------------------------|----------|
| <b>1</b> | <b>Word2Vec基本数学内容</b>         | <b>5</b> |
| 1.1      | Sigmoid 函数 . . . . .          | 5        |
| 1.2      | 贝叶斯公式 . . . . .               | 5        |
| 1.3      | Huffman 树和Huffman编码 . . . . . | 6        |
| <b>2</b> | <b>语言模型</b>                   | <b>7</b> |
| 2.1      | 统计语言模型的基本原理 . . . . .         | 7        |
| 2.2      | 主要的统计语言模型 . . . . .           | 8        |
| 2.2.1    | 上下文无关模型 . . . . .             | 8        |
| 2.2.2    | n-gram模型 . . . . .            | 8        |
| <b>3</b> | <b>Hierarchical Softmax模型</b> | <b>9</b> |
| 3.1      | 词向量 . . . . .                 | 9        |
| 3.2      | CBOW模型 . . . . .              | 10       |
| 3.2.1    | CBOW模型介绍 . . . . .            | 10       |
| 3.2.2    | CBOW模型的推导 . . . . .           | 11       |
| 3.3      | Skip-gram模型 . . . . .         | 14       |
| 3.3.1    | Skip-gram模型介绍 . . . . .       | 14       |

|          |                            |           |
|----------|----------------------------|-----------|
| 3.3.2    | Skip-gram模型的目标函数 . . . . . | 15        |
| 3.3.3    | Skip-gram模型的推导过程 . . . . . | 16        |
| <b>4</b> | <b>Negative Sampling模型</b> | <b>19</b> |
| 4.1      | CBOW . . . . .             | 20        |
| 4.2      | Skip-gram模型 . . . . .      | 22        |
| <b>5</b> | <b>Word2Vec训练同义词模型</b>     | <b>23</b> |
| 5.1      | 需求描述 . . . . .             | 23        |
| 5.2      | 数据处理 . . . . .             | 23        |
| 5.3      | 工具选择 . . . . .             | 24        |
| 5.4      | 模型训练步骤简述 . . . . .         | 24        |
| 5.5      | 重要调参目标 . . . . .           | 25        |
| 5.6      | 模型的实际效果 . . . . .          | 25        |
| 5.7      | 可以跑的CODE . . . . .         | 25        |
| <b>6</b> | <b>Spark下的word2vec模型训练</b> | <b>29</b> |
| 6.1      | 引言 . . . . .               | 29        |
| 6.2      | 分词 . . . . .               | 29        |
| 6.3      | 模型训练 . . . . .             | 30        |
| <b>7</b> | <b>Word2Vec 的重点参考文献</b>    | <b>31</b> |

# Chapter 1

## Word2Vec基本数学内容

### 1.1 Sigmoid 函数

Sigmoid函数通常在二分类中应用。它将样本映射后投影在 $[0, 1]$ 范围内，对应样本所属的类的概率。函数表达式如下所示：

$$f(x) = \frac{1}{1 + e^{-x}} \quad (1.1)$$

具体的讨论可以参见：

[Logistic Function AND Softmax Function](#)

### 1.2 贝叶斯公式

$$P(A|B) = \frac{P(B|A)P(A)}{P(B)} \quad (1.2)$$

可以参见贝叶斯分类等一系列文章：

1. [朴素贝叶斯分类](#)

2. 朴素贝叶斯算法的后验概率最大化含义
3. 朴素贝叶斯法的参数估计

## 1.3 Huffman 树和Huffman编码

下边这篇博客写的很详细了，这里简单引用一些基本知识：

### 哈夫曼树

定义哈夫曼树之前先说明几个与哈夫曼树有关的概念：

**路径：**树中一个结点到另一个结点之间的分支构成这两个结点之间的路径。

**路径长度：**路径上的分枝数目称作路径长度。

**树的路径长度：**从树根到每一个结点的路径长度之和。

**结点的带权路径长度：**在一棵树中，如果其结点上附带有一个权值，通常把该结点的路径长度与该结点上的权值之积称为该结点的带权路径长度（weighted path length）

**树的带权路径长度：**如果树中每个叶子上都带有一个权值，则把树中所有叶子的带权路径长度之和称为树的带权路径长度。

一般来说，用 $n(n > 0)$ 个带权值的叶子来构造二叉树，限定二叉树中除了这 $n$ 个叶子外只能出现度为2的结点。那么符合这样条件的二叉树往往可构造出许多颗，其中带权路径长度最小的二叉树就称为**哈夫曼树**或**最优二叉树**。

通过哈夫曼树来构造的编码称为**哈弗曼编码(huffman code)**

# Chapter 2

## 语言模型

语言模型可以分为文法型模型和统计语言模型。在实际应用中语言识别、手写体文字识别、机器翻译、键盘输入、信息检索等研究领域都用到了语言模型。文法型语言模型是人工编制的语言学文法，文法规则来源于语言学家掌握的语言学知识和领域知识，但这种语言模型不能处理大规模真实文本。因此，统计语言模型出现了，并且得到了广泛的应用，统计语言模型是基于概率的，包括了N元文法模型（N-gram Model）、隐马尔科夫模型（Hidden Markov Model，简称HMM）、最大熵模型（Maximum Entropy Model）。

### 2.1 统计语言模型的基本原理

统计语言模型是以概率分布的形式说明了一个字符串出现的概率。假设词（word）是语言的最小单位，句子S是由一系列的词 $w_1, w_2, \dots, w_k$ 顺序构成，则句子S的概率为下：

$$\begin{aligned} p(s) &= p(w_1)p(w_2|w_1)\dots p(w_n|w_1, w_2, \dots, w_{n-1}) \\ &= \prod_{i=1}^n p(w_i|w_1, w_2, \dots, w_{i-1}) \end{aligned} \tag{2.1}$$

且，上式中约定 $p(w_1|w_0) = p(w_1)$ 。观察上式可以发现，句子S的概率计

算是很复杂的，因此，往往采用一些方法来估计语料库中句子的概率。

## 2.2 主要的统计语言模型

### 2.2.1 上下文无关模型

上下文无关模型就是词 $w_1$ 的出现与它所处的环境无关，仅仅是它在语料中出现的概率，即它是n-gram中 $n=1$ 的情况，但是实际上，这种方法效果并不是很好。

### 2.2.2 n-gram模型

n-gram模型是要考虑上下文的。 $w_1$ 出现的是依赖于它之前的 $n-1$ 个词的，即需要计算词表中的每一个 $n-1$ 元组的概率，此计算量是巨大的，因此实际中，常取 $n=2$  或 $n=3$ .



## Chapter 3

# Hierarchical Softmax模型

### 3.1 词向量

词向量目前常用的有2种表示方法，One-hot representation 和distributed representation. 词向量，顾名思义就是将一个词表示为向量的形式，一个词，怎么可以将其表现为向量呢？最简单的就是**One-hot representation**，它是以词典V中的词的个数作为向量的维度，按照字典序或某种特定的顺序将V排序后，词w的向量可以表示为： $[0, 0, 1, 0, 0, \dots, 0]$ ，即词w出现的位置为1，其余均为0. 可以看到，这种方法表示的词向量太过于稀疏，维度太高，会引起维度灾难，而且非常不利于计算词之间的相似度。另一种**distributed representation** 可以解决上述问题，它通过训练将一个词映射为相对于One-hot representation来说一个比较短的向量，它的表示形式类似于： $[0.1, 0.34, 0.673, 0.983]$ 。词向量就是将词映射到词典空间中，如下图所示的词向量是两种不同的语言映射。




Figure 3.1: 词向量在空间中的映射

## 3.2 CBOW模型

### 3.2.1 CBOW模型介绍

CBOW模型很像feedforward NNLM(A Neural Probabilistic Language Model), feedforward NNLM模型如下所示:

其中C是一个词向量矩阵, 首先, 将词 $w_i$ 的词向量从C中取出, 并且首尾相接组成 $\mathbf{x}$ 作为神经网络的第一层输入层, 第二层为隐藏层, 通过 $d + Hx$ 计算得到。 $d$ 是一个偏置项。在此之后, 使用tanh 作为激活函。第三层输出层, 一共有 $|V|$  个节点, 每个节点 $y_i$  表示下一个词为 $i$ 的未归一化log 概率。最后使用softmax 激活函数将输出值 $y$  归一化成概率。最终,  $y$  的计算公式为:  $y = b + Wx + U \tanh(d + Hx)$ 。

CBOW将隐藏层移除, 投影层不再是词向量的拼接, 而是各个词向量相加后取平均作为输入, 由上图可以看到, NNLM模型大部分的计算量在输出层上的softmax归一化运算, 因此, CBOW为了简化模型, 在输出层输出huffman树。CBOW模型根据上下文预测当前词。Skip-gram模型是用每个当前词去预测一定范围内除当前词之外前后的词。并不是有些人说的CBOW的相反版本。论文关于这一点的原文是: **we use each current word as an input to a log-linear classifier with continuous**




Figure 1: Neural architecture:  $f(i, w_{t-1}, \dots, w_{t-n+1}) = g(i, C(w_{t-1}), \dots, C(w_{t-n+1}))$  where  $g$  is the neural network and  $C(i)$  is the  $i$ -th word feature vector.

Figure 3.2: feedforward NNLM模型

projection layer, and predict words within a certain range before and after the current word. [原文pdf](#)

### 3.2.2 CBOW模型的推导

由于模型的输出是一颗huffman树，其中树的叶子节点表示词，根节点表示权值。CBOW的核心内容是推导出 $p(w|context(w))$ ,其中， $context(w)$ 由 $w$ 前后各 $c$ 个词组成。如下图所示：下图借用[基于Hierarchical Softmax 的模型](#)。

1. 由输入层 $context(w)$ 得到投影层向量 $\mathbf{X}_w$ :

$$\mathbf{X}_w = \sum_{i=1}^{2c} \mathbf{V}(context(w)_i) \quad (3.1)$$

以上 $\mathbf{V}(context(w)_i)$ 初始化为 $[-\frac{0.5}{M}, \frac{0.5}{M}]$ ,  $M$ 为向量的维数。

2. 由huffman树的根节点到叶节点，是多个二分类问题。二分类问题一

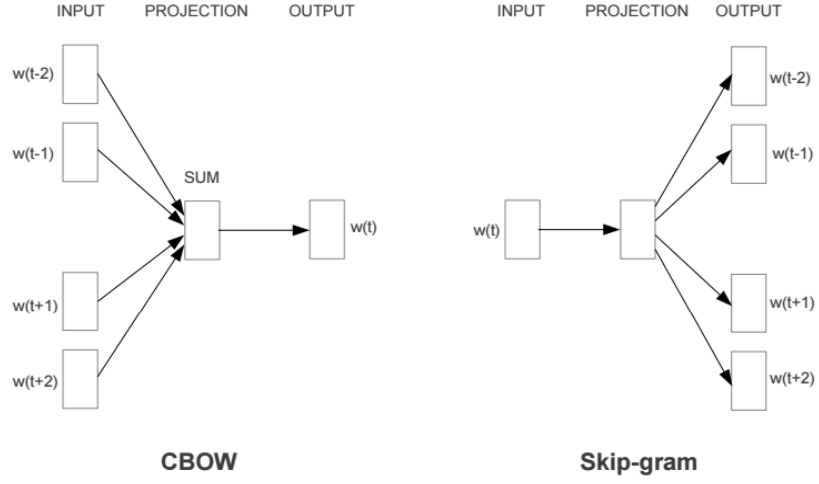


Figure 1: New model architectures. The CBOW architecture predicts the current word based on the context, and the Skip-gram predicts surrounding words given the current word.

Figure 3.3: CBOW模型和Skip-gram模型

般用logistic回归解决，给出回归函数：

$$\sigma(z_i) = \frac{1}{1 + e^{-z_i}}, \quad (3.2)$$

其中， $z = \mathbf{X}_w^T \boldsymbol{\theta}$ ，则

$$\begin{cases} p(d_i^w | \mathbf{X}_w^T; \boldsymbol{\theta}_{i-1}) = 1 - \sigma(z) & , d = 1 \\ p(d_i^w | \mathbf{X}_w^T; \boldsymbol{\theta}_{i-1}) = \sigma(z) & , d = 0 \end{cases} \quad (3.3)$$

3. 由以上huffman树的图可知：

$$p(w | context(w)) = \prod_{i=2}^{l^w} p(d_i^w | \mathbf{X}_w; \boldsymbol{\theta}_{i-1}) = \prod_{i=2}^{l^w} [\sigma(z_{i-1})^{1-d_i^w} (1-\sigma(z_{i-1}))^{d_i^w}] \quad (3.4)$$


图 11  $w = \text{“足球”}$  时的相关记号示意图

Figure 3.4: CBOW模型示意图

4. 语言模型的目标函数是取如下最大似然函数

$$\begin{aligned}
 \mathcal{L} &= \sum_{w \in \mathcal{C}} \log p(w | \text{context}(w)) \\
 &= \sum_{w \in \mathcal{C}} \log \prod_{i=2}^{l^w} [\sigma(z_{i-1})^{1-d_i^w} (1 - \sigma(z_{i-1}))^{d_i^w}] \\
 &= \sum_{w \in \mathcal{C}} \sum_{i=2}^{l^w} [(1 - d_i^w) \log \sigma(z_{i-1}) + d_i^w \log (1 - \sigma(z_{i-1}))]
 \end{aligned} \tag{3.5}$$

记以下函数为:

$$\mathcal{L}(w, i) = (1 - d_i^w) \log \sigma(z_{i-1}) + d_i^w \log(1 - \sigma(z_{i-1})) \quad (3.6)$$

将 $z_i$ 代入得:

$$\mathcal{L}(w, i) = (1 - d_i^w) \log \sigma(\mathbf{X}_w^T \boldsymbol{\theta}_{i-1}) + d_i^w \log(1 - \sigma(\mathbf{X}_w^T \boldsymbol{\theta}_{i-1})) \quad (3.7)$$

5. 求函数 $\mathcal{L}(w, i)$ 对 $w$ 和 $\theta_{i-1}$ 求偏导数:

$$\frac{\partial \mathcal{L}(w, i)}{\partial \mathbf{X}_w} = (1 - d_i^w - \frac{1}{1 + e^{-\mathbf{X}_w^T \boldsymbol{\theta}_{i-1}}}) \boldsymbol{\theta}_{i-1} \quad (3.8)$$

$$\frac{\partial \mathcal{L}(w, i)}{\partial \boldsymbol{\theta}_{i-1}} = (1 - d_i^w - \frac{1}{1 + e^{-\mathbf{X}_w^T \boldsymbol{\theta}_{i-1}}}) \mathbf{X}_w^T \quad (3.9)$$

6. 那么, 参数 $\theta_{i-1}$ 的更新公式如下所示:

$$\theta_{i-1} := \theta_{i-1} + \eta (1 - d_i^w - \frac{1}{1 + e^{-\mathbf{X}_w^T \boldsymbol{\theta}_{i-1}}}) \mathbf{X}_w^T \quad (3.10)$$

我们的目的是求每个词的词向量, 那么, 给出词向量的更新公式: 对于每个 $w \in \text{context}(w)$ , 都有:

$$v(w) := v(w) + \eta \sum_{i=2}^{l_w} (1 - d_i^w - \frac{1}{1 + e^{-\mathbf{X}_w^T \boldsymbol{\theta}_{i-1}}}) \boldsymbol{\theta}_{i-1} \quad (3.11)$$

## 3.3 Skip-gram模型

### 3.3.1 Skip-gram模型介绍

Skip-gram模型并不是和CBOW模型相反的, 它们的目的都是计算出词的向量, 只不过在作者的论文中给出的图看样子是反的而已。Skip-gram模型是用每个当前词去预测一定范围内除当前词之外前后的词。同样的, 此模型也是输出一颗huffman树, 如下图所示: 此图也借用下图借用基于Hierarchical Softmax 的模型




Figure 3.5: huffman树

### 3.3.2 Skip-gram模型的目标函数

由于Skip-gram的模型输入是当前词，目的是预测它周围的词，因此，此任务的目标函数如下所示：

$$\mathcal{L} = \sum_{w \in C} \log P(\text{context}(w) | w) \quad (3.12)$$

由于 $context(w)$  是一个句子，因此，可以将 $P(context(w)|w)$ 写成如下形式：

$$P(context(w)|w) = \prod_{u \in context(w)} P(u|w) \quad (3.13)$$

根据hierarchical softmax的讨论：

$$P(u|w) = \prod_{j=2}^{l^u} P(d_j^u | v(u); \theta_{j-1}) \quad (3.14)$$

那么：最终的目标函数可以写为：

$$\mathcal{L} = \sum_{w \in C} \log \prod_{u \in context(w)} \prod_{j=2}^{l^u} P(d_j^u | v(u); \theta_{j-1}) \quad (3.15)$$

### 3.3.3 Skip-gram模型的推导过程

$$\begin{aligned} \mathcal{L} &= \sum_{w \in C} \log \prod_{u \in context(w)} \prod_{j=2}^{l^u} P(d_j^u | v(u); \theta_{j-1}) \\ &= \sum_{w \in C} \sum_{u \in context(w)} \sum_{j=2}^{l^u} \log P(d_j^u | v(u); \theta_{j-1}) \\ &= \sum_{w \in C} \sum_{u \in context(w)} \sum_{j=2}^{l^u} \log \{ [1 - \sigma(v(w)^T \theta_{j-1}^u)]^{d_j^u} \sigma(v(w)^T \theta_{j-1}^u)^{1-d_j^u} \} \\ &= \sum_{w \in C} \sum_{u \in context(w)} \sum_{j=2}^{l^u} \{ d_j^u \log[1 - \sigma(v(w)^T \theta_{j-1}^u)] + (1 - d_j^u) \log[\sigma(v(w)^T \theta_{j-1}^u)] \} \end{aligned} \quad (3.16)$$

令

$$f = d_j^u \log[1 - \sigma(v(w)^T \theta_{j-1}^u)] + (1 - d_j^u) \log[\sigma(v(w)^T \theta_{j-1}^u)] \quad (3.17)$$

则分别求出 $f$ 对 $\theta_j$  和 $v(w)$ 求偏导数：

$$\frac{\partial f}{\partial \theta_{j-1}^u} = [1 - d_j^u - \sigma(v(w)^T \theta_{j-1}^u)] v(w) \quad (3.18)$$



$$\frac{\partial f}{\partial v(w)} = [1 - d_j^u - \sigma(v(w)^T \theta_{j-1}^u)] \theta_{j-1}^u \quad (3.19)$$

那么 $\theta$ 和 $v(w)$ 的更新公式如下:

$$\theta_{j-1}^u := \theta_{j-1}^u + \eta [1 - d_j^u - \sigma(v(w)^T \theta_{j-1}^u)] v(w) \quad (3.20)$$

$$v(w) := v(w) + \sum_{u \in \text{context}(w)} \sum_{j=2}^{l^u} [1 - d_j^u - \sigma(v(w)^T \theta_{j-1}^u)] \theta_{j-1}^u \quad (3.21)$$



## Chapter 4

# Negative Sampling模型

在负采样中，对于给定的词 $w$ ，如何生成它的负采样集合 $NEG(w)$ 呢？已知一个词 $w$ ，它的上下文是 $context(w)$ ，那么词 $w$ 就是一个正例，其他词就是一个负例。但是负例样本太多了，我们怎么去选取呢？在语料库 $\mathcal{C}$ 中，各个词出现的频率是不一样的，我们采样的时候要求高频词选中的概率较大，而低频词选中的概率较小。这就是一个带权采样的问题。设词典 $\mathcal{D}$ 中的每一个词 $w$ 对应线段的一个长度：

$$len(w) = \frac{counter(w)}{\sum_{u \in \mathcal{D}} counter(u)} (1) \quad (4.1)$$

式4.1分母是为了归一化，Word2Vec中的具体做法是：记 $l_0 = 0, l_k = \sum_{j=1}^k len(w_j), k = 1, 2, \dots, N$ ，其中， $w_j$ 是词典 $\mathcal{D}$ 中的第 $j$ 个词，则以 $\{l_j\}_{j=0}^N$ 为点构成了一个在区间 $[0,1]$ 非等距离的划分。然后再加一个等距离划分，Word2Vec中选取 $M = 10^8$ ，将 $M$ 个点等距离的分布在区间 $[0,1]$ 上，这样就构成了 $M$ 到 $I$ 之间的一个映射，如下图所示：

图例参考：[建议大家读下这篇神作](#)。

选取负例样本的时候，取 $[M_0, M_{m-1}]$ 上的一个随机数，对应到 $I$ 上就可以了。如果对于词 $w_i$ ，正好选到它自己，则跳过。负例样本集合 $NEG(w)$ 的大小在Word2Vec源码中默认选5。

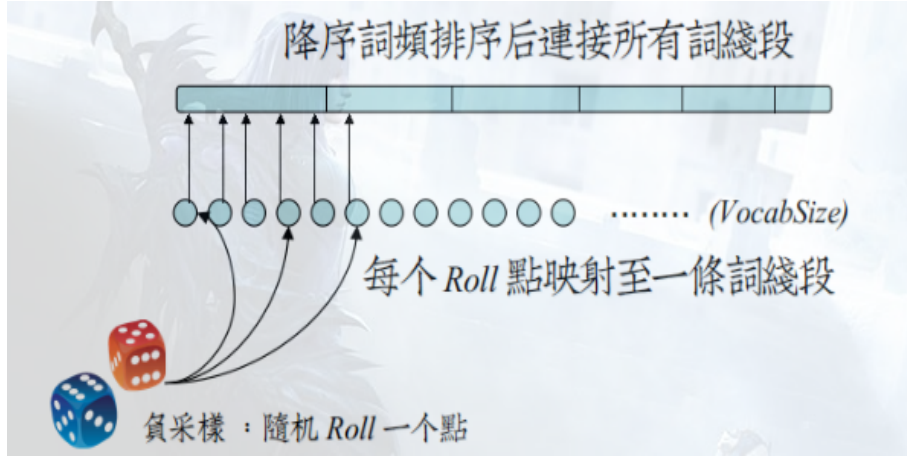


Figure 4.1: 負採樣

## 4.1 CBOW

假定关于词 $w$ 的负例样本 $NEG(w)$ 已经选出,定义标签 $L$ 如下, 对于 $\forall \tilde{w} \in \mathcal{D}$ :

$$L^w(\tilde{w}) = \begin{cases} 1, & \tilde{w} = w; \\ 0, & \tilde{w} \neq w; \end{cases} \quad (4.2)$$

对于给定的一个正例样本( $context(w), w$ ), 要求:

$$\max g(w) = \max \prod_{u \in \{w\} \cup u \in NEG(w)} p(u|context(w)) \quad (4.3)$$

其中,

$$p(u|context(w)) = \begin{cases} \sigma(\mathbf{x}_w^T \theta^u), & L^w(u) = 1 \\ 1 - \sigma(\mathbf{x}_w^T \theta^u), & L^w(u) = 0 \end{cases} \quad (4.4)$$

把它写成一个式子:

$$p(u|context(w)) = \sigma(\mathbf{x}_w^T \theta^u)^{L^w(u)} + (1 - \sigma(\mathbf{x}_w^T \theta^u))^{1-L^w(u)} \quad (4.5)$$

下边解释为什么要最大化 $g(w)$ ,

$$\begin{aligned}
 g(w) &= \prod_{u \in \{w\} \cup u \in NEG(w)} p(u | context(w)) \\
 &= \prod_{u \in \{w\} \cup u \in NEG(w)} \sigma(\mathbf{x}_w^T \boldsymbol{\theta}^u)^{L^w(u)} + (1 - \sigma(\mathbf{x}_w^T \boldsymbol{\theta}^u))^{1-L^w(u)} \\
 &= \sigma(\mathbf{x}_w^T \boldsymbol{\theta}^w) \prod_{u \in NEG(w)} (1 - \sigma(\mathbf{x}_w^T \boldsymbol{\theta}^u))
 \end{aligned} \tag{4.6}$$

上式中连乘号前边的式子可以解释为最大化正例样本概率，连乘号后边解释为最小化负例样本概率。

同样的，针对于语料库，令：

$$\mathcal{G} = \prod_{w \in \mathcal{C}} g(w) \tag{4.7}$$

可以将上式作为整体的优化目标函数，取上式的最大似然：

$$\begin{aligned}
 \mathcal{L} &= \log \mathcal{G} \\
 &= \sum_{w \in \mathcal{C}} \log g(w) \\
 &= \sum_{w \in \mathcal{C}} \sum_{u \in \{w\} \cup u \in NEG(w)} L^w(u) \log[\sigma(\mathbf{x}_w^T \boldsymbol{\theta}^u)] + [1 - L^w(u)] \log[1 - \sigma(\mathbf{x}_w^T \boldsymbol{\theta}^u)]
 \end{aligned} \tag{4.8}$$

和之前的计算过程一样，记

$$L(w, u) = L^w(u) \log[\sigma(\mathbf{x}_w^T \boldsymbol{\theta}^u)] + [1 - L^w(u)] \log[1 - \sigma(\mathbf{x}_w^T \boldsymbol{\theta}^u)] \tag{4.9}$$

然后分别求： $\frac{\partial L(w, u)}{\partial \mathbf{X}_w}$ 和 $\frac{\partial L(w, u)}{\partial \boldsymbol{\theta}^u}$ ,求解过程略过：

$$\frac{\partial L(w, u)}{\partial \mathbf{X}_w} = [L^w(u) - \sigma(\mathbf{x}_w^T \boldsymbol{\theta}^u)] \boldsymbol{\theta}^u \tag{4.10}$$

$$\frac{\partial L(w, u)}{\partial \boldsymbol{\theta}^u} = [L^w(u) - \sigma(\mathbf{x}_w^T \boldsymbol{\theta}^u)] \mathbf{X}_w \tag{4.11}$$

则，可得到如下更新公式：

$$\boldsymbol{\theta}^u := \boldsymbol{\theta}^u + \eta[L^w(u) - \sigma(\mathbf{x}_w^T \boldsymbol{\theta}^u)] \mathbf{X}_w \quad (4.12)$$

$$v(\tilde{\mathbf{w}}) := v(\tilde{\mathbf{w}}) + \sum_{u \in \{w\} \cup u \in NEG(w)} [L^w(u) - \sigma(\mathbf{x}_w^T \boldsymbol{\theta}^u)] \boldsymbol{\theta}^u \quad (4.13)$$

其中， $\tilde{\mathbf{w}} \in context(w)$ 。

## 4.2 Skip-gram模型

这部分内容并不多，与cbow相比，只是目标函数有所变化，推导过程这里就略过。总的来说，就是将目标函数取最大似然，然后利用SGD方法求出词向量和最优参数。目标函数如下所示：

$$G = \prod_{w \in \mathcal{C}} g(w) \quad (4.14)$$

其中， $g(w)$ 可以改写成如下形式：

$$g(w) = \prod_{u \in context(w)} g(u) \quad (4.15)$$

$g(u)$ 表示如下：

$$g(u) = \prod_{z \in \{u\} \cup NEG(u)} p(z|w) \quad (4.16)$$

其中， $NEG(u)$ 表示在处理词 $u$ 时产生的负样本集合。 $p(z|w)$ 如下：

$$p(z|w) = \begin{cases} \sigma(\mathbf{v}(\mathbf{w})^T \boldsymbol{\theta}^z), & L^u(z) = 1 \\ 1 - \sigma(\mathbf{v}(\mathbf{w})^T \boldsymbol{\theta}^z), & L^u(z) = 0 \end{cases} \quad (4.17)$$

将以上式子合并之后就可以得到最终的目标函数：

$$G = \prod_{w \in \mathcal{C}} \prod_{u \in context(w)} \prod_{z \in \{u\} \cup NEG(u)} \sigma(\mathbf{v}(\mathbf{w})^T \boldsymbol{\theta}^z)^{L^u(z)} (1 - \sigma(\mathbf{v}(\mathbf{w})^T \boldsymbol{\theta}^z))^{1-L^u(z)} \quad (4.18)$$

然后取 $G$ 的最大似然对数，求目标函数的最优化。

## Chapter 5

# Word2Vec训练同义词模型

### 5.1 需求描述

业务需求的目标是识别出目标词汇的同义词和相关词汇，如下为部分目标词汇(主要用于医疗问诊):

- 尿
- 痘痘
- 发冷
- 呼吸困难
- 恶心

数据源是若干im数据，那么这里我们选择google 的word2vec模型来训练同义词和相关词。

### 5.2 数据处理

数据处理考虑以下几个方面:

1. 从hive中导出不同数据量的数据
2. 过滤无用的训练样本（例如字数少于5）
3. 准备自定义的词汇表
4. 准备停用词表

### 5.3 工具选择

选择python 的gensim库，由于先做预研，数据量不是很大,选择单机就好，暂时不考虑spark训练。后续生产环境计划上spark。[详细的gensim中word2vec文档](#)

上述文档有关工具的用法已经很详细了，就不多说。

分词采用jieba。

### 5.4 模型训练步骤简述

1. 先做分词、去停用词处理

```
seg_word_line = jieba.cut(line, cut_all = True)
```

2. 将分词的结果作为模型的输入

```
model = gensim.models.Word2Vec(  
    LineSentence(source_separated_words_file),  
    size=200, window=5, min_count=5, alpha=0.02,  
    workers=4)
```

3. 保存模型，方便以后调用，获得目标词的同义词

```
similary_words = model.most_similar(w, topn=10)
```



## 5.5 重要调参目标

比较重要的参数:

- 训练数据的大小，当初只用了10万数据，训练出来的模型很不好，后边不断地将训练语料增加到800万，效果得到了明显的提升
- 向量的维度，这是词汇向量的维数，这个会影响到计算，理论上来说维数大一点会好。
- 学习速率
- 窗口大小

在调参上，并没有花太多精力，因为目测结果还好，到时上线使用前再仔细调整。

## 5.6 模型的实际效果

Table 5.1: 同义词

| 目标词  | 同义词相关词                               |
|------|--------------------------------------|
| 尿    | 尿液,撒尿,尿急,尿尿有,尿到,内裤,尿意,小解,前列腺炎,小便     |
| 痘痘   | 逗逗,豆豆,痘子,小痘,青春痘,红痘,长痘痘,粉刺,讽刺,白头      |
| 发冷   | 发烫,没力,忽冷忽热,时冷时热,小柴胡,头昏,嗜睡,38.9,头晕,发寒 |
| 呼吸困难 | 气来,气紧,窒息,大气,透不过气,出不上,濒死,粗气,压气,心律不齐   |
| 恶心   | 闷,力气,呕心,胀气,涨,不好受,不进,晕车,闷闷,精神         |

## 5.7 可以跑的CODE

```
import codecs
import jieba
import gensim
from gensim.models.word2vec import LineSentence

def read_source_file(source_file_name):
    try:
        file_reader = codecs.open(source_file_name, 'r', 'utf-8', errors="ignore")
        lines = file_reader.readlines()
        print("Read complete!")
        file_reader.close()
        return lines
    except:
        print("There are some errors while reading.")

def write_file(target_file_name, content):

    file_write = codecs.open(target_file_name, 'w+', 'utf-8')
    file_write.writelines(content)
    print("Write sussfully!")
    file_write.close()

def separate_word(filename, user_dic_file, separated_file):
    print("separate_word")
    lines = read_source_file(filename)
    #jieba.load_userdict(user_dic_file)
    stopkey=[line.strip() for line in codecs.open('stopword_zh.txt', 'r', 'utf-8').readlines()]

    output = codecs.open(separated_file, 'w', 'utf-8')
    num = 0
    for line in lines:
        num = num + 1
        if num% 10000 == 0:
```

```
        print("Processing line number: " + str(num))
    seg_word_line = jieba.cut(line, cut_all = True)
    wordls = list(set(seg_word_line)-set(stopkey))
    if len(wordls)>0:
        word_line = ' '.join(wordls) + '\n'
        output.write(word_line)
    output.close()
    return separated_file

def build_model(source_separated_words_file,model_path):

    print("start building...",source_separated_words_file)
    model = gensim.models.Word2Vec(LineSentence(
                                                source_separated_words_file
                                                ), size=200, window=5,
                                                min_count=5, alpha=0.02,
                                                workers=4)

    model.save(model_path)
    print("build successful!", model_path)
    return model

def get_similar_words_str(w, model, topn = 10):
    result_words = get_similar_words_list(w, model)
    return str(result_words)

def get_similar_words_list(w, model, topn = 10):
    result_words = []
    try:
        similary_words = model.most_similar(w, topn=10)
        print(similary_words)
        for (word, similarity) in similary_words:
            result_words.append(word)
        print(result_words)
    except:
        print("There are some errors!" + w)
```

```
    return result_words

def load_models(model_path):
    return gensim.models.Word2Vec.load(model_path)

if "__name__ == '__main__'":
    filename = "d:\\data\\dk_mainsuit_800w.txt" #source file
    user_dic_file = "new_dict.txt" # user dic file
    separated_file = "d:\\data\\dk_spe_file_20170216.txt" #
        separated words file
    model_path = "information_model0830" # model file

    #source_separated_words_file = separate_word(filename,
        user_dic_file,
        separated_file)

    source_separated_words_file = separated_file # if
        separated word file exist,
        don't separate_word again
    build_model(source_separated_words_file, model_path) # if
        model file is exist, don't
        buile modl

    model = load_models(model_path)
    words = get_similar_words_str('headache', model)
    print(words)
```

## Chapter 6

# Spark下的word2vec模型训练

### 6.1 引言

前边一节介绍了Word2Vec模型训练同义词，那么在大数据量的情况下，我们自然想到了用spark来进行训练下面就介绍我们是如何实现spark上的模型训练。

### 6.2 分词

模型训练的输入是分好词的语料，那么就得实现spark上的分词。

```
def split(jieba_list, iterator):  
    sentences = []  
    for i in iterator:  
        try:  
            seg_list = []  
            #out_str = ""  
            s = ""  
            for c in i:  
                if not c is None:  
                    s += c.encode('utf-8')
```

```
id = s.split("__")[0]
s = s.split("__")[1]
wordList = jieba.cut(s, cut_all=False)
for word in wordList:
    out_str += word
    out_str += " "
sentences.append(out_str)
except:
    continue
return sentences
```

## 6.3 模型训练

这里，直接用分词后的rdd对象作为输入

```
word2vec = Word2Vec().setNumPartitions(50)
spark.sql("use jkgj_log")
df = spark.sql("select label1_name,label2_name from
                mid_dim_tag ")

df_list = df.collect()
spark.sparkContext.broadcast(df_list)

diagnosis_text_in = spark.sql("select main_suit,
                               msg_content from diagnosis_text_in
                               where
                               pt>='
                               20170101
                               '")

inp = diagnosis_text_in.rdd.repartition(1200)
    .mapPartitions(lambda it: split(df_list,it))
    .map(lambda row: row.split(" "))

model = word2vec.fit(inp)
```

# Chapter 7

## Word2Vec 的重点参考文献

1. Efficient Estimation of Word Representations in Vector Space.
2. Distributed Representations of Words and Phrases and their Compositionality
3. Exploiting Similarities among Languages for Machine Translation
4. 基于Hierarchical Softmax 的模型
5. Word2Vec源码解析
6. word2vec中关于霍夫曼树的应用原理